

Липецкий государственный технический университет

Кафедра прикладной математики

## **КОМПЬЮТЕРНЫЕ ТЕХНОЛОГИИ МАТЕМАТИЧЕСКИХ ИССЛЕДОВАНИЙ**

Лекция 9

### **11. Анализ временных рядов**

Составитель - Сысоев А.С., к.т.н., доцент

Липецк - 2022

## Outline

---

- 11.1. Задачи анализа временных рядов
- 11.2. Создание объектов типа временной ряд в среде R
- 11.3. Процедура скользящего среднего в среде R
- 11.4. Сезонная декомпозиция в среде R
- 11.5. Экспоненциальные модели прогнозирования временных рядов в среде R
- 11.6. Модели ARIMA в среде R

## 11.1. Задачи анализа временных рядов

---



Данные бывают:

- Перекрестными – предполагается наблюдение за многими однотипными объектами с целью получения информации о процессе / объекте / системе.
- Долгосрочными (лонгитюдными) – изучается одна и та же группа объектов в течении долгого времени, за которое эти объекты успевают существенным образом поменять какие-либо свои значимые признаки.

Возможно выстроить результаты наблюдения таким образом, чтобы они образовывали временной ряд  $Y_1, Y_2, Y_3, \dots, Y_t, \dots, Y_T$ .

Анализ временных рядов строится для решения двух основных задач:

1. Исследовать то, что происходит (задача описания).
2. Сказать, что будет дальше (задача прогноза).



## 11.2. Создание объектов типа временной ряд в среде R

---

Необходимые составляющие объекта типа временной ряд:

- Непосредственно наблюдения,
- Время начала и конца рассматриваемого временного периода,
- Информация о периодичности (месячные данные, квартальные или годовые).

```
myseries <- ts(data, start=, end=, frequency=)
```

```
> sales <- c(18, 33, 41, 7, 34, 35, 24, 25, 24, 21, 25, 20,
             22, 31, 40, 29, 25, 21, 22, 54, 31, 25, 26, 35)
> tsales <- ts(sales, start=c(2003, 1), frequency=12)
> tsales
      Jan Feb Mar Apr May Jun Jul Aug Sep Oct Nov Dec
2003  18  33  41   7  34  35  24  25  24  21  25  20
2004  22  31  40  29  25  21  22  54  31  25  26  35
> plot(tsales)
> start(tsales)
[1] 2003    1
> end(tsales)
[1] 2004   12
> frequency(tsales)
[1] 12
> tsales.subset <- window(tsales, start=c(2003, 5), end=c(2004, 6))
> tsales.subset
      Jan Feb Mar Apr May Jun Jul Aug Sep Oct Nov Dec
2003           34  35  24  25  24  21  25  20
2004  22  31  40  29  25  21
```

←  
**1** Creates a  
time-series  
object

←  
**2** Gets information  
about the object

Subsets the object **3**

## 11.3. Процедура скользящего среднего в среде R

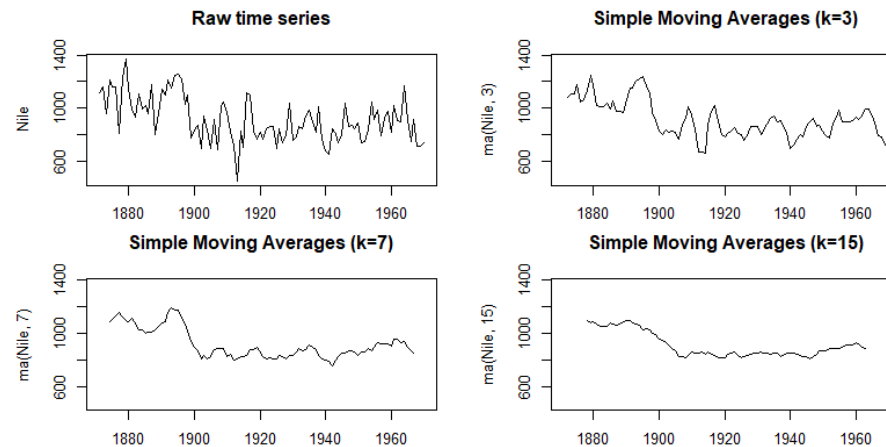
Обычно временные ряды имеют значимую нерегулярную компоненту или ошибку.

Подход – использовать процедуру скользящего среднего.

Центрированное скользящее среднее (теряется  $(k - 1) / 2$  значений)

$$S_t = (Y_{t-q} + \dots + Y_t + \dots + Y_{t+q}) / (2q + 1)$$

```
library(forecast)
opar <- par(no.readonly=TRUE)
par(mfrow=c(2,2))
ylim <- c(min(Nile), max(Nile))
plot(Nile, main="Raw time series")
plot(ma(Nile, 3), main="Simple Moving Averages (k=3)", ylim=ylim)
plot(ma(Nile, 7), main="Simple Moving Averages (k=7)", ylim=ylim)
plot(ma(Nile, 15), main="Simple Moving Averages (k=15)", ylim=ylim)
par(opar)
```



## 11.4. Сезонная декомпозиция в среде R


Временной ряд, у которого присутствует сезонная составляющая (месячная или квартальная периодичность), можно разложить на тренд, сезонную компоненту и ошибку.

Декомпозиция может быть представлена аддитивной или мультипликативной моделями.


$$Y_t = \text{Trend}_t + \text{Seasonal}_t + \text{Irregular}_t$$

$$Y_t = \text{Trend}_t * \text{Seasonal}_t * \text{Irregular}_t$$


(a) Stationary




(b) Additive Trend and Irregular Components




(c) Additive Seasonal and Irregular Components



(d) Additive Trend, Seasonal, and Irregular Components



(e) Multiplicative Trend, Seasonal, and Irregular Components



## 11.4. Сезонная декомпозиция в среде R



---

Популярный метод декомпозиции в R – loess (Local regrESSion).

```
stl(ts, s.window=, t.window=)
```

Такой подход применяется только к аддитивным моделям. В случае мультипликативных моделей используется линеаризация:

$$\begin{aligned}\log(Y_t) &= \log(\text{Trend}_t * \text{Seasonal}_t * \text{Irregular}_t) = \\ &= \log(\text{Trend}_t) + \log(\text{Seasonal}_t) + \log(\text{Irregular}_t)\end{aligned}$$



## 11.4. Сезонная декомпозиция в среде R

---

```
> plot(AirPassengers)
> lAirPassengers <- log(AirPassengers)
> plot(lAirPassengers, ylab="log(AirPassengers)")
```

←  
**1** Plots the time series

```
> fit <- stl(lAirPassengers, s.window="period")
> plot(fit)
```

←  
**2** Decomposes the time series

```
> fit$time.series
```

←  
**3** Components for each observation


	seasonal	trend	remainder
Jan 1949	-0.09164	4.829	-0.0192494
Feb 1949	-0.11403	4.830	0.0543448
Mar 1949	0.01587	4.831	0.0355884
Apr 1949	-0.01403	4.833	0.0404633
May 1949	-0.01502	4.835	-0.0245905
Jun 1949	0.10979	4.838	-0.0426814
Jul 1949	0.21640	4.841	-0.0601152
Aug 1949	0.20961	4.843	-0.0558625
Sep 1949	0.06747	4.846	-0.0008274
Oct 1949	-0.07025	4.851	-0.0015113
Nov 1949	-0.21353	4.856	0.0021631
Dec 1949	-0.10064	4.865	0.0067347
...	output omitted	...	...

```
> exp(fit$time.series)
```



	seasonal	trend	remainder
Jan 1949	0.9124	125.1	0.9809
Feb 1949	0.8922	125.3	1.0558
Mar 1949	1.0160	125.4	1.0362
Apr 1949	0.9861	125.6	1.0413
May 1949	0.9851	125.9	0.9757
Jun 1949	1.1160	126.2	0.9582
Jul 1949	1.2416	126.6	0.9417
Aug 1949	1.2332	126.9	0.9457
Sep 1949	1.0698	127.2	0.9992
Oct 1949	0.9322	127.9	0.9985
Nov 1949	0.8077	128.5	1.0022
Dec 1949	0.9043	129.6	1.0068
...	output omitted	...	...



## 11.4. Сезонная декомпозиция в среде R



```
par(mfrow=c(2,1))  
library(forecast)  
monthplot(AirPassengers, xlab="", ylab="")  
seasonplot(AirPassengers, year.labels="TRUE", main="")
```



## 11.5. Экспоненциальные модели прогнозирования временных рядов в среде R

---

Экспоненциальные модели, используемые для прогнозирования временных рядов:

- single exponential model (используется для рядов с постоянным уровнем и ошибкой, но без тренда и сезонной составляющей);
- double exponential model (Holt exponential smoothing) для рядов с постоянным уровнем и трендом.
- triple exponential model (Holt-Winters exponential smoothing) для рядов с постоянным уровнем, трендом и сезонной составляющей.

Функция `ets()` из пакета `forecast`:

`ets(ts, model="ZZZ")`

Доступные опции:

- A – аддитивные модели,
- M – мультипликативные модели,
- N – не указано,
- Z – автоматический выбор.

Type	Parameters fit	Functions
simple	level	<code>ets(ts, model="ANN")</code> <code>ses(ts)</code>
double	level, slope	<code>ets(ts, model="AAN")</code> <code>holt(ts)</code>
triple	level, slope, seasonal	<code>ets(ts, model="AAA")</code> <code>hw(ts)</code>

## 11.5. Экспоненциальные модели прогнозирования временных рядов в среде R


Простое экспоненциальное скользящее:

$$Y_t = \text{level} + \text{irregular}_t$$

Прогнозное значение для уровня  $Y_{t+1}$

$$Y_{t+1} = c_0 Y_t + c_1 Y_{t-1} + c_2 Y_{t-2} + c_2 Y_{t-2} + \dots$$

$$c_i = \alpha(1-\alpha)^i, i = 0, 1, 2, \dots \text{ and } 0 \leq \alpha \leq 1.$$



```
> library(forecast)
> fit <- ets(nhtemp, model="ANN") 1 Fits the model
> fit
ETS(A,N,N)
Call:
ets(y = nhtemp, model = "ANN")
Smoothing parameters:
  alpha = 0.182
Initial states:
  l = 50.2759
sigma: 1.126
AIC AICc BIC
263.9 264.1 268.1 2 I-step ahead forecast
> forecast(fit, 1)
      Point Forecast Lo 80 Hi 80 Lo 95 Hi 95
1972      51.87 50.43 53.31 49.66 54.08
> plot(forecast(fit, 1), xlab="Year",
      ylab=expression(paste("Temperature (", degree*"F,"")),
      main="New Haven Annual Mean Temperature")
> accuracy(fit) 3 Prints accuracy measures
      ME  RMSE  MAE  MPE  MAPE  MASE
Training set 0.146 1.126 0.8951 0.2419 1.749 0.9228
```

## 11.5. Экспоненциальные модели прогнозирования временных рядов в среде R

accuracy()

Measure	Abbreviation	Definition
Mean error	ME	$\text{mean}(e_t)$
Root mean squared error	RMSE	$\sqrt{\text{mean}(e_t^2)}$
Mean absolute error	MAE	$\text{mean}( e_t )$
Mean percentage error	MPE	$\text{mean}(100 * e_t / Y_t)$
Mean absolute percentage error	MAPE	$\text{mean}( 100 * e_t / Y_t )$
Mean absolute scaled error	MASE	$\text{mean}( q_t )$ where $q_t = e_t / (1/(T-1) * \sum( y_t - y_{t-1} ))$ , T is the number of observations, and the sum goes from $t=2$ to $t=T$


## 11.5. Экспоненциальные модели прогнозирования временных рядов в среде R

Экспоненциальное скользящее Хольта:

$$Y_t = \text{level} + \text{slope} * t + \text{irregular}_t$$

Экспоненциальное скользящее Хольта-Винтерса:

$$Y_t = \text{level} + \text{slope} * t + s_t + \text{irregular}_t$$



```
> library(forecast)
> fit <- ets(log(AirPassengers), model="AAA")
> fit
ETS (A,A,A)
Call:
ets(y = log(AirPassengers), model = "AAA")
Smoothing parameters: 1 Smoothing parameters
  alpha = 0.8528
  beta  = 4e-04
  gamma = 0.0121
Initial states:
  l = 4.8362
  b = 0.0097
  s = -0.1137 -0.2251 -0.0756 0.0623 0.2079 0.2222
      0.1235 -0.009 0 0.0203 -0.1203 -0.0925
sigma: 0.0367
  AIC  AICc  BIC
-204.1 -199.8 -156.5
> accuracy(fit)
           ME      RMSE      MAE      MPE      MAPE      MASE
Training set -0.0003695 0.03672 0.02835 -0.007882 0.5206 0.07532
```

```
> pred <- forecast(fit, 5) 2 Future forecasts
> pred
      Point Forecast Lo 80 Hi 80 Lo 95 Hi 95
Jan 1961      6.101 6.054 6.148 6.029 6.173
Feb 1961      6.084 6.022 6.146 5.989 6.179
Mar 1961      6.233 6.159 6.307 6.120 6.346
Apr 1961      6.222 6.138 6.306 6.093 6.350
May 1961      6.225 6.131 6.318 6.082 6.367

> plot(pred, main="Forecast for Air Travel",
       ylab="Log(AirPassengers)", xlab="Time")
> pred$mean <- exp(pred$mean)
> pred$lower <- exp(pred$lower)
> pred$upper <- exp(pred$upper) 3 Makes forecasts in the original scale
> p <- cbind(pred$mean, pred$lower, pred$upper)
> dimnames(p)[[2]] <- c("mean", "Lo 80", "Lo 95", "Hi 80", "Hi 95")
> p
      mean Lo 80 Lo 95 Hi 80 Hi 95
Jan 1961 446.3 425.8 415.3 467.8 479.6
Feb 1961 438.8 412.5 399.2 466.8 482.3
Mar 1961 509.2 473.0 454.9 548.2 570.0
Apr 1961 503.6 463.0 442.9 547.7 572.6
May 1961 505.0 460.1 437.9 554.3 582.3
```

## 11.6. Модели ARIMA в среде R

---

Lag	1869	1870	1871	1872	1873	1874	1875	...
0			1120	1160	963	1210	1160	...
1		1120	1160	963	1210	1160	1160	...
2	1120	1160	963	1210	1160	1160	813	...

Лаг – сдвиг влево временного ряда на заданное число наблюдений ( $\text{lag}(ts, k)$ )

Автокорреляция – оценивает силу связи, которой связаны уровни ряда с некоторым лагом.

График автокорреляционной функции  $\text{Acf}(ts)$

Частная автокорреляция

Стационарность, разность

Дополненная процедура Дикки-Фуллера - `adf.test()` из пакета `tseries`

## 11.6. Модели ARIMA в среде R

---

Авторегрессионная модель порядка  $p$

$$AR(p): Y_t = \mu + \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + \dots + \beta_p Y_{t-p} + \varepsilon_t$$

Модель скользящего среднего порядка  $q$

$$MA(q): Y_t = \mu - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} \dots - \theta_q \varepsilon_{t-q} + \varepsilon_t$$

ARMA( $p, q$ )

$$Y_t = \mu + \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + \dots + \beta_p Y_{t-p} - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} \dots - \theta_q \varepsilon_{t-q} + \varepsilon_t$$

ARIMA( $p, d, q$ ) Находятся разности  $d$  раз. Прогнозные значения получены на основании  $p$  текущих значений и  $q$  предыдущих ошибок. Прогнозные значения «интегрированы».

Применение модели ARIMA

1. Убедиться, что временной ряд стационарен.
2. Идентифицировать модель (выбрать  $p$  и  $q$ ).
3. Подогнать модель.
4. Оценить модель.
5. Сделать прогноз.

## 11.6. Модели ARIMA в среде R

### ПРОВЕРКА СТАЦИОНАРНОСТИ РЯДА


```
> library(forecast)
> library(tseries)
> plot(Nile)
> ndiffs(Nile)
```

```
[1] 1
```

```
> dNile <- diff(Nile)
> plot(dNile)
> adf.test(dNile)
```

Augmented Dickey-Fuller Test

```
data: dNile
Dickey-Fuller = -6.5924, Lag order = 4, p-value = 0.01
alternative hypothesis: stationary
```







## 11.6. Модели ARIMA в среде R

### ИДЕНТИФИКАЦИЯ МОДЕЛИ

Model	ACF	PACF
ARIMA(p, d, 0)	Trails off to zero	Zero after lag p
ARIMA(0, d, q)	Zero after lag q	Trails off to zero
ARIMA(p, d, q)	Trails off to zero	Trails off to zero

`Acf(dNile)`

`Pacf(dNile)`



## 11.6. Модели ARIMA в среде R

---

### ПОДГОНКА МОДЕЛИ

```
> library(forecast)
> fit <- arima(Nile, order=c(0,1,1))
> fit

Series: Nile
ARIMA(0,1,1)

Coefficients:
          ma1
        -0.7329
s.e.      0.1143

sigma^2 estimated as 20600:  log likelihood=-632.55
AIC=1269.09   AICc=1269.22   BIC=1274.28

> accuracy(fit)

              ME  RMSE  MAE   MPE  MAPE  MASE
Training set -11.94 142.8 112.2 -3.575 12.94 0.8089
```

## 11.6. Модели ARIMA в среде R


---

### ОЦЕНКА МОДЕЛИ

```
> qqnorm(fit$residuals)
> qqline(fit$residuals)
> Box.test(fit$residuals, type="Ljung-Box")
```

Box-Ljung test

```
data: fit$residuals
X-squared = 1.3711, df = 1, p-value = 0.2416
```




## 11.6. Модели ARIMA в среде R

### ПРОГНОЗИРОВАНИЕ

```
> forecast(fit, 3)
```

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
1971	798.3673	614.4307	982.3040	517.0605	1079.674
1972	798.3673	607.9845	988.7502	507.2019	1089.533
1973	798.3673	601.7495	994.9851	497.6663	1099.068

```
> plot(forecast(fit, 3), xlab="Year", ylab="Annual Flow")
```



## 11.6. Модели ARIMA в среде R

---

### Автоматическое прогнозирование модели ARIMA

```
> library(forecast)
> fit <- auto.arima(sunspots)
> fit
Series: sunspots
ARIMA(2,1,2)

Coefficients:
      ar1      ar2      ma1      ma2
      1.35  -0.396  -1.77   0.810
s.e.   0.03   0.029   0.02   0.019

sigma^2 estimated as 243:  log likelihood=-11746
AIC=23501   AICc=23501   BIC=23531

> forecast(fit, 3)

      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
Jan 1984      40.437722  20.4412613  60.43418   9.855774  71.01967
Feb 1984      41.352897  18.2795867  64.42621   6.065314  76.64048
Mar 1984      39.796425  15.2537785  64.33907   2.261686  77.33116

> accuracy(fit)
      ME RMSE      MAE MPE MAPE MASE
Training set -0.02673 15.6 11.03 NaN  Inf  0.32
```

## Литература

---

**Robert I. Kabacoff** R in Action, Second Edition. Data analysis and graphics with R